

Benchmark Report

ASR & NMT — FLEURS + VIVOS

KAVI Prototype — 2026

Internal Draft

Authors: KAVI Team
Date: 2026-10-02
Status: Draft

Mục lục

Mục lục	2
1. Tổng quan & Mục tiêu	4
1.1. Mục tiêu	4
1.2. Phạm vi benchmark	4
1.3. Tóm tắt dataset & metrics	4
1.4. Câu hỏi nghiên cứu	4
2. Tổng quan các Model	5
2.1. Neural Machine Translation	5
2.1.1. Opus-MT (Helsinki-NLP)	5
2.1.2. M2M-100 (facebook/m2m100_418M)	5
2.1.3. HY-MT1.5-1.8B (Tencent HunYuan)	5
2.2. Automatic Speech Recognition	5
2.2.1. Whisper Small (faster-whisper)	6
2.2.2. Moonshine Tiny (vi / en)	6
2.2.3. Zipformer-30M (vi / en, sherpa-onnx)	6
3. Dataset Benchmark	6
3.1. FLEURS	6
3.2. VIVOS	6
3.3. VietSuperSpeech (VSS)	6
4. Thiết lập thử nghiệm	7
4.1. Phần cứng & Môi trường	7
4.2. Cấu hình Benchmark	7
4.2.1. ASR	7
4.2.2. NMT	7
4.3. Beam-sweep summary	7
5. Kết quả Benchmark ASR	8
5.1. Chất lượng nhận dạng (WER trung bình)	8
5.2. Phân tích WER theo điều kiện nhiễu (SNR × noise type)	9
5.2.1. FLEURS — steady noise	9
5.2.2. FLEURS — impulsive noise	9
5.2.3. VIVOS — steady & impulsive	9
5.3. Biểu đồ	10
6. Kết quả Benchmark NMT	13
6.1. Chất lượng dịch (BLEU)	13
6.1.1. Full-pool (347 items)	13
6.1.2. Gold-set (42 items, gồm 12 mục gold-mt)	13
6.2. Hiệu suất tính toán	13
6.3. Biểu đồ	14
7. Phân tích & Thảo luận	14
7.1. Phân tích theo Chất lượng	14
7.1.1. ASR: Zipformer-vi dẫn đầu, nhất quán trên cả 2 dataset	14
7.1.2. Whisper-vi yếu hơn Whisper-en	14
7.1.3. Moonshine-vi: trung bình, nhạy cảm steady noise	14
7.1.4. NMT: M2M-100 vs HY-MT — “lexical match” vs “fluent paraphrase”	14
7.2. Phân tích theo Hiệu suất	15
7.2.1. Edge device (RAM < 1 GB, latency thấp)	15

7.2.2. Server / chất lượng tối đa	15
7.2.3. Trade-off chất lượng vs tốc độ	15
7.2.4. Giới hạn phần cứng	15
8. Kết luận & Khuyến nghị	16
8.1. Khuyến nghị theo use-case	16
8.1.1. Edge device (RAM < 1 GB, latency < 1 s)	16
8.1.2. Server (chất lượng tối đa)	16
8.1.3. Hybrid edge-server (đề xuất pipeline)	16
8.2. Tổng kết	16
8.3. Hướng phát triển	16
9. Phụ lục	17
9.1. Reproducibility	17
9.2. Limitations	17
9.3. Chi tiết SNR grid (FLEURS ASR)	18
9.4. Chi tiết SNR grid (VIVOS ASR)	18

1. Tổng quan & Mục tiêu

1.1. Mục tiêu

Báo cáo này đánh giá và so sánh hiệu năng của các mô hình ASR (nhận dạng tiếng nói) và NMT (dịch máy) trên nền tảng prototype KAVI — một hệ thống CPU-only chạy cục bộ trên máy tính cá nhân. Mục đích là xác định tổ hợp mô hình phù hợp nhất cho pipeline **ASR tiếng Việt → dịch sang tiếng Anh**, với tiêu chí cân bằng giữa chất lượng nhận dạng/dịch (WER, BLEU) và chi phí tính toán (latency, RAM).

Benchmark được thiết kế theo hai trục:

- **Chất lượng:** WER trên 2 dataset ASR tiếng Việt (FLEURS + VIVOS) với lưới điều kiện nhiễu 9 mức (clean + steady/impulsive noise @ 15/10/5/0 dB), và BLEU trên tập MT vi→en.
- **Hiệu suất:** latency trung bình (s), peak RAM (MB), và RTF (real-time factor) cho từng mô hình trên cùng một phần cứng.

1.2. Phạm vi benchmark

- **NMT:** 3 candidates
 - Opus-MT
 - M2M-100
 - HY-MT1.5-1.8B (HF Transformers, latency không so sánh với CT2, xem Phần 2.1.3).
- **ASR:** 5 candidates
 - Whisper Small
 - Moonshine-vi
 - Moonshine-en
 - Zipformer-vi
 - Zipformer-en

1.3. Tóm tắt dataset & metrics

- Dataset: FLEURS (vi/en), VIVOS (vi) — xem Phần 3.
- Metrics:
 - ASR: WER, CER (jiwer, lowercase normalized).
 - Metrics NMT: BLEU (mean per-item sacrebleu, case-sensitive; không phải corpus BLEU).
- Metrics hiệu suất: latency (s), peak RAM (MB), RTF.

1.4. Câu hỏi nghiên cứu

1. Mô hình ASR nào đạt WER thấp nhất cho tiếng Việt trên FLEURS và VIVOS? Kết quả có nhất quán giữa hai dataset không?
2. Các mô hình suy giảm WER thế nào khi nhiễu nền tăng (steady vs impulsive, 15 → 0 dB)? Mô hình nào robust nhất với nhiễu?
3. Mô hình NMT nào dịch vi→en tốt nhất theo BLEU? HY-MT1.5 (1.8B) có vượt trội M2M-100 (418M) và Opus-MT không?
4. Đánh đổi giữa chất lượng và hiệu suất: mô hình nào phù hợp cho edge device (RAM < 1 GB, latency thấp), mô hình nào cho server?
5. Pipeline ASR vi → MT có khả thi chạy CPU-only trên phần cứng Core i7-1165G7 4 nhân không?

2. Tổng quan các Model

2.1. Neural Machine Translation

Tổng hợp 3 mô hình NMT tham gia benchmark:

Model	Kiến trúc	Params	Checkpoint	Runtime
Opus-MT	encoder-decoder	74M	Helsinki-NLP/opus-mt-vi-en	CT2 int8
M2M-100	encoder-decoder	418M	facebook/m2m100_418M	CT2 int8
HY-MT1.5	decoder-only	1.8B	tencent/HY-MT1.5-1.8B	HF Transformers bf16

Bảng 1: Tổng hợp các mô hình NMT tham gia benchmark.

2.1.1. Opus-MT (Helsinki-NLP)

- Cặp ngôn ngữ cố định vi→en (v0, weights en→vi chưa có trong repo).
- Inference offline qua CTranslate2 int8, SentencePiece tokenizer.
- Beam size 5 + repetition_penalty 1.1 + no_repeat_ngram 3 (sweep phase chọn).
- Ưu điểm: nhẹ (74M params), latency thấp, RAM ~400 MB.
- Nhược điểm: BLEU thấp nhất trong 3 mô hình (xem Phần 6).

2.1.2. M2M-100 (facebook/m2m100_418M)

- Encoder-decoder đa ngôn ngữ; cần target_prefix en để ép đầu ra tiếng Anh.
- Inference offline qua CTranslate2 int8, CT2 translator + SentencePiece.
- Beam size 4.
- Ưu điểm: chất lượng BLEU cao nhất full-pool; hỗ trợ đa ngôn ngữ.
- Nhược điểm: RAM 1.1 GB (cao nhất nhóm CT2).

2.1.3. HY-MT1.5-1.8B (Tencent HunYuan)

- Kiến trúc: HunYuanDenseV1 (decoder-only CausalLM, không phải encoder-decoder).
- Issue #91: CT2 không convert được (custom arch + dynamic RoPE + QK-norm).
- Runtime: HF Transformers CPU, bf16 — latency 50 s/inference, RAM 3.8 GB.
- Latency HY-MT không thuận lợi so với CT2-int8 (opus/m2m) — chỉ so sánh BLEU.
- Hiện chỉ có gold-set (42 items, BLEU 15.64); full-pool chưa chạy.

2.2. Automatic Speech Recognition

Tổng hợp 5 mô hình ASR tham gia benchmark:

Model	Kiến trúc	Params	Ngôn ngữ	Runtime
Whisper Small	encoder-decoder	244M	vi/en	faster-whisper
Moonshine Tiny vi	encoder-decoder	27M	vi	HF Transformers
Moonshine Tiny en	encoder-decoder	27M	en	HF Transformers
Zipformer-30M	transducer	30M	vi	sherpa-onnx int8
Zipformer-EN	transducer	90M	en	sherpa-onnx int8

Bảng 2: Tổng hợp các mô hình ASR tham gia benchmark.

2.2.1. Whisper Small (faster-whisper)

- Multilingual; ngôn ngữ chỉ định per-item (vi/en), beam 2.
- Chạy qua faster-whisper (CTranslate2-backed), model_size "small".

2.2.2. Moonshine Tiny (vi / en)

- Single-language: moonshine-tiny-vi và moonshine-tiny (en), chạy qua HF Transformers.
- Beam 1 (vi) / beam 4 (en), no_repeat_ngram 3, max_length 448 (đủ cho utterance 15s).

2.2.3. Zipformer-30M (vi / en, sherpa-onnx)

- Transducer (encoder-decoder-joiner), sherpa-onnx OfflineRecognizer.
- Beam $\geq 2 \rightarrow$ modified_beam_search (max_active_paths=beam); beam 1 $\rightarrow$ greedy.
- Zipformer-vi: beam 5, int8 encoder. Zipformer-en: beam 4.
- **Lưu ý:** Zipformer-vi được train trên VSS (xem Phần 3.3) — tránh dùng VSS để eval model này.

3. Dataset Benchmark

Dataset	Ngôn ngữ	Số item	Cấu trúc
FLEURS	vi, en	540 (ASR) / 347 (MT)	30 + 30 base $\times$ 9 conditions
VIVOS	vi	900	100 base $\times$ 9 conditions
VSS	vi	reference only	chỉ dùng làm reference text

Bảng 3: Tổng quan các dataset benchmark.

3.1. FLEURS

- Nguồn: google/fleurs (HuggingFace), tập test tiếng Việt + tiếng Anh.
- Split: test. 30 base utterances mỗi ngôn ngữ $\times$ 9 điều kiện SNR = 270 items/language.
- 9 conditions: clean + steady noise + impulsive noise @ 15/10/5/0 dB.
- **Đặc điểm tham chiếu:** transcript FLEURS là informal spoken-language $\rightarrow$ BLEU thường thấp hơn so với text formal (ảnh hưởng interpretation).

3.2. VIVOS

- Nguồn: VIVOS corpus.
- Ngôn ngữ: vi. Split: test.
- 100 utterances $\times$ 9 conditions = 900 items; cùng SNR grid như FLEURS.
- Giọng đọc sạch, đọc chuẩn $\rightarrow$ dễ nhận dạng hơn FLEURS (WER thấp hơn rõ rệt ở mọi model).

3.3. VietSuperSpeech (VSS)

- Zipformer được train trên VSS.
- VSS chỉ được dùng làm reference text cho các model ASR còn lại (Moonshine, Whisper), KHÔNG dùng để eval Zipformer (tránh train/test overlap).
- **Hệ quả:** Zipformer-vi có lợi thế trên VIVOS (cùng miền giọng đọc chuẩn với VSS) — kết quả cần đọc với lưu ý này (xem Phần 9.2).

4. Thiết lập thử nghiệm

4.1. Phần cứng & Môi trường

Thông số	Chi tiết
CPU	11th Gen Intel(R) Core(TM) i7-1165G7 @ 2.80GHz (Tiger Lake, 4C/8T)
RAM	15.7GB DDR4
GPU	— (CPU-only evaluation)
Framework	PyTorch 2.12.1+cpu, Transformers 4.57.6, CTranslate2 4.8.0, sherpa-onnx 1.12.40
Precision	bf16 (HF models), int8 (CT2 models)
Batch size	1 (per-item inference)

Bảng 4: Thông số phần cứng và môi trường chạy benchmark.

Lưu ý: HY-MT chạy HF Transformers eager, bf16 — đo thực tế trên CPU này cho thấy fp32 nhanh hơn bf16 (xem Phần 7).

4.2. Cấu hình Benchmark

4.2.1. ASR

- Ngôn ngữ chỉ định: vi hoặc en theo item (không auto-detect).
- Decode: beam search (beam tối ưu từ sweep phase, xem Phần 4.3).
- Audio resample về 16 kHz.
- **Text normalization:** lowercase cả ref và hyp (jiwer case-sensitive; Zipformer output ALL-CAP). Không bỏ dấu câu, không bỏ số.

4.2.2. NMT

- Cặp ngôn ngữ: vi → en. Beam size: opus-mt - 5, m2m100 - 4, hy-mt - 5.
- Max length: 256 tokens.
- BLEU: sacrebleu default (case-sensitive, lowercase=False).

4.3. Beam-sweep summary

Beam tối ưu từ sweep phase (archive bench-results/archive/beam-sweep/):

Model	Beam tối ưu	Ghi chú
Whisper Small	2	cân bằng WER/latency
Moonshine-vi	1	greedy tốt hơn beam
Moonshine-en	4	
Zipformer-vi	5	modified_beam_search
Zipformer-en	4	
Opus-MT	5	chống repetition loop
M2M-100	4	
HY-MT	5	deterministic beam, so sánh BLEU

Bảng 5: Beam size tối ưu từ sweep phase cho từng model.

5. Kết quả Benchmark ASR

5.1. Chất lượng nhận dạng (WER trung bình)

FLEURS (5 candidates × 2 ngôn ngữ):

Candidate	Language	Mean WER	Latency (s)	RTF	RAM (MB)
Whisper Small	vi	0.3835	3.69	0.27	923
Whisper Small	en	0.2189	3.22	0.32	923
Moonshine Tiny	vi	0.3998	1.76	0.12	528
Moonshine Tiny	en	0.3286	1.41	0.13	566
Zipformer-30M	vi	0.128	0.58	0.04	674
Zipformer-EN	en	0.3523	0.64	0.06	677

Bảng 6: WER trung bình, latency, RTF và RAM trên FLEURS (vi/en).

VIVOS (3 candidates, vi):

Candidate	Mean WER	Latency (s)	RTF	RAM (MB)
Whisper Small	0.3641	3.03	0.92	923
Moonshine Tiny	0.2591	0.48	0.14	510
Zipformer-30M	0.0564	0.14	0.04	383

Bảng 7: WER trung bình, latency, RTF và RAM trên VIVOS (vi).

Finding: Zipformer-vi thấp nhất cả 2 dataset (FLEURS 0.128, VIVOS 0.0564); Whisper-vi cao WER trên cả 2; Moonshine-vi tốt hơn Whisper-vi trên VIVOS nhưng kém hơn trên FLEURS.

5.2. Phân tích WER theo điều kiện nhiễu (SNR × noise type)

Finding chính: steady noise degrade mạnh theo SNR; impulsive noise degrade ít. Ví dụ Moonshine-vi trên FLEURS: steady 0.3058 → 0.7701 (tăng mạnh) vs impulsive 0.3194 → 0.3835 (tăng nhẹ).

5.2.1. FLEURS — steady noise

Model	Clean	15 dB	10 dB	5 dB	0 dB
Moonshine-en	0.2728	0.2648	0.2905	0.4123	0.6479
Moonshine-vi	0.2815	0.3058	0.3499	0.5013	0.7701
Whisper-en	0.1598	0.1877	0.214	0.2576	0.4039
Whisper-vi	0.3013	0.3134	0.4328	0.4445	0.6909
Zipformer-en	0.2857	0.2715	0.3144	0.4274	0.672
Zipformer-vi	0.0997	0.1146	0.1253	0.1477	0.2088

Bảng 8: FLEURS — WER theo SNR dưới steady noise.

5.2.2. FLEURS — impulsive noise

Model	Clean	15 dB	10 dB	5 dB	0 dB
Moonshine-en	0.2728	0.2578	0.2608	0.2738	0.2768
Moonshine-vi	0.2815	0.3194	0.3398	0.3469	0.3835
Whisper-en	0.1598	0.1842	0.1819	0.1849	0.1957
Whisper-vi	0.3013	0.3042	0.3113	0.31	0.3429
Zipformer-en	0.2857	0.3004	0.3005	0.2973	0.3017
Zipformer-vi	0.0997	0.1069	0.1097	0.1184	0.1206

Bảng 9: FLEURS — WER theo SNR dưới impulsive noise.

5.2.3. VIVOS — steady & impulsive

Model	Clean	15 dB	10 dB	5 dB	0 dB
Moonshine-vi	0.2009	0.1731	0.1909	0.2547	0.4981
Whisper-vi	0.3463	0.3308	0.3364	0.3939	0.5214
Zipformer-vi	0.0513	0.0498	0.0491	0.0608	0.0924


Bảng 10: VIVOS — WER theo SNR dưới steady noise.

Model	Clean	15 dB	10 dB	5 dB	0 dB
Moonshine-vi	0.2009	0.2084	0.217	0.2598	0.3287
Whisper-vi	0.3463	0.3415	0.3409	0.336	0.3302
Zipformer-vi	0.0513	0.055	0.0482	0.0504	0.0503

Bảng 11: VIVOS — WER theo SNR dưới impulsive noise.


5.3. Biểu đồ

FLEURS ASR — mean WER by condition




Hình 1: FLEURS ASR — mean WER theo SNR. Đường steady degrade mạnh; impulsive gần như nằm ngang.

VIVOS ASR (vi) — mean WER by condition




Hình 2: VIVOS ASR (vi) — mean WER theo SNR.


ASR quality vs speed (vi; bubble = peak RAM)




Hình 3: ASR quality vs speed (vi). Trục X: latency (log scale), Y = WER (thấp = tốt), bubble = peak RAM.




Hình 4: FLEURS ASR — heatmap WER (candidate × condition) - steady noise.



Hình 5: FLEURS ASR - heatmap WER (candidate × condition) - impulsive noise.



Hình 6: VIVOS ASR — heatmap WER (candidate × condition) - steady noise.



Hình 7: VIVOS ASR — heatmap WER (candidate × condition) - impulsive noise.

6. Kết quả Benchmark NMT

6.1. Chất lượng dịch (BLEU)

Lưu ý: HY-MT chỉ có gold-set (42 items, HF CPU 55 s/inference); opus/m2m có full-pool (347 items, CT2-int8 1 s). Chỉ số sánh BLEU; latency không comparable.

6.1.1. Full-pool (347 items)

Candidate	Mean BLEU	Median	Min	Max
Opus-MT	9.84	7.1	0.72	56
M2M-100	17.5	14.12	1.95	60.13

Bảng 12: BLEU trên full-pool (347 items).

6.1.2. Gold-set (42 items, gồm 12 mục gold-mt)

Candidate	Mean BLEU	Median	Min	Max
Opus-MT	10.78	7.13	1.1	36.72
M2M-100	18.99	15.42	3.18	58.59
HY-MT1.5	15.64	9.28	2	70.7

Bảng 13: BLEU trên gold-set (42 items, gồm 12 mục gold-mt).

Trên 12 mục gold-only (không tính 30 mục vi-en-mt còn lại): HY-MT 25.87 · M2M-100 23.49 · Opus-MT 15.19 — HY-MT dẫn đầu.


6.2. Hiệu suất tính toán

Candidate	Mean latency (s)	Peak RAM (MB)	Runtime
Opus-MT	1.64	399	CT2 int8
M2M-100	0.97	1102	CT2 int8
HY-MT1.5	54.98	3802	HF bf16

Bảng 14: Hiệu suất tính toán của các mô hình NMT.

Cảnh báo: HY-MT chạy HF Transformers eager, bf16 — latency 55 s/inference gấp 50 lần CT2 (một phần do eager inference; bf16 đo chậm hơn fp32 trên CPU này, xem Phần 7). Con số chỉ mang tính tham chiếu; BLEU mới là metric so sánh được (xem Phần 2.1.3).

6.3. Biểu đồ



Hình 8: FLEURS MT vi→en — BLEU vs latency (log scale), bubble = peak RAM.

7. Phân tích & Thảo luận

7.1. Phân tích theo Chất lượng

7.1.1. ASR: Zipformer-vi dẫn đầu, nhất quán trên cả 2 dataset

- FLEURS: Zipformer-vi 0.128 VIVOS: 0.0564 — thấp nhất ở mọi điều kiện SNR.
- VIVOS dễ hơn FLEURS rõ rệt cho mọi model (giọng đọc chuẩn, ít informal speech).
- **Lưu ý contamination:** Zipformer-vi train trên VSS — VIVOS cùng miền giọng đọc nên kết quả VIVOS có lợi thế không công bằng (xem Phần 9.2).

7.1.2. Whisper-vi yếu hơn Whisper-en

- Whisper-vi WER cao hơn Whisper-en trên FLEURS (0.3835 vs 0.2189) — tiếng Việt khó hơn (tone, informal).
- 3 item FLEURS whisper vượt WER 1.0 (repetition loops ở SNR thấp — hành vi thật của model, không phải lỗi pipeline).

7.1.3. Moonshine-vi: trung bình, nhạy cảm steady noise

- VIVOS: Moonshine-vi (0.2591) tốt hơn Whisper-vi (0.3641) — nhưng FLEURS thì ngược lại.
- Steady noise 0 dB làm Moonshine-vi tăng WER mạnh nhất (FLEURS 0.7701).

7.1.4. NMT: M2M-100 vs HY-MT — “lexical match” vs “fluent paraphrase”

- Full-pool: M2M-100 (17.5) > Opus-MT (9.84).
- Gold-set: M2M-100 (18.99) > HY-MT (15.64) > Opus-MT (10.78) — nhưng HY-MT thắng trên 12 mục gold-only (25.87 vs 23.49).

- Giải thích: FLEURS reference là informal spoken transcripts; HY-MT sinh fluent paraphrase lệch từ vựng → BLEU bị phạt. M2M-100 bám sát từ vựng hơn → BLEU cao hơn dù câu kém tự nhiên hơn.

7.2. Phân tích theo Hiệu suất

7.2.1. Edge device (RAM < 1 GB, latency thấp)

- Zipformer-vi: VIVOS latency 0.14 s, RAM 383 MB — ứng viên số 1.
- Moonshine-vi: RAM 510 MB, latency 0.48 s (VIVOS) — chấp nhận được, WER tốt hơn Whisper.
- Whisper: RAM 923 MB + latency 3 s — không phù hợp edge, phù hợp server/desktop.

7.2.2. Server / chất lượng tối đa

- ASR: Whisper Small (đa ngôn ngữ, WER en thấp nhất 0.2189) — linh hoạt nhất.
- MT: M2M-100 (BLEU cao nhất, RAM 1102 MB) — chọn cho server.

7.2.3. Trade-off chất lượng vs tốc độ

- RTF Zipformer-vi 0.04 (VIVOS) — ~25× nhanh hơn real-time; Whisper-vi 0.92 — sát ngưỡng real-time, biên an toàn rất mỏng, dễ tụt xuống > 1 nếu hardware yếu hơn.
- **Lưu ý RTF:** không so sánh chéo dataset (Whisper có fixed overhead ~3.3 s/item bất kể độ dài clip — xem benchmark-results-fleurs-vivos.md §4).

7.2.4. Giới hạn phần cứng

- CPU-only Core i7-1165G7 (Tiger Lake; có AVX-512/BF16 nhưng không có AMX) — HY-MT chạy HF eager, bf16 55 s/inference (54.98); probe riêng cho thấy fp32 nhanh hơn (1.21 vs 1.51 s/token), dẫn đến ước tính 44 s/item — nhưng bf16 vẫn chậm do eager kernels HF chưa tối ưu.
- Nếu chạy GPU hoặc float8/quantized kernels, HY-MT latency kỳ vọng giảm đáng kể — con số hiện tại không phản ánh chất lượng runtime thật.

8. Kết luận & Khuyến nghị

8.1. Khuyến nghị theo use-case

8.1.1. Edge device (RAM < 1 GB, latency < 1 s)

- **ASR vi:** Zipformer-vi — WER 0.0564 (VIVOS) / 0.128 (FLEURS), latency 0.14 s, RAM 383 MB.
- **MT: không ứng viên nào đạt cả hai ngưỡng** — M2M-100 đạt độ trễ 0.97 s nhưng RAM 1102 MB vượt ngưỡng 1 GB; Opus-MT đạt RAM 399 MB nhưng độ trễ 1.64 s **vượt ngưỡng 1 s**, đổi lại BLEU 9.84 thấp hơn M2M. Chọn Opus-MT khi bộ nhớ là ràng buộc cứng; nếu ưu tiên độ trễ thì chọn M2M-100 và chấp nhận bộ nhớ.

8.1.2. Server (chất lượng tối đa)

- **ASR:** Whisper Small — đa ngôn ngữ, WER en tốt nhất (0.2189).
- **MT:** M2M-100 — BLEU 17.5 full-pool; RAM 1102 MB chấp nhận được cho server.

8.1.3. Hybrid edge-server (đề xuất pipeline)

ASR vi edge (Zipformer-vi) → MT cloud/server (M2M-100). Nếu MT phải chạy on-device → Opus-MT (đủ tốt, nhẹ).

8.2. Tổng kết

- **ASR vi:** Zipformer-vi thắng toàn diện (nhỏ, nhanh, chính xác) — nhưng cần ghi nhận contamination VSS/VIVOS. Whisper-vi là lựa chọn thay thế đa ngôn ngữ.
- **NMT vi→en:** M2M-100 tốt nhất theo BLEU; Opus-MT nhẹ nhất; HY-MT1.5 chất lượng promising (gold-only BLEU 25.87) nhưng chưa deployable (issue 91, latency HF CPU).
- **Pipeline đề xuất:** Zipformer-vi (edge) → M2M-100 (server).

8.3. Hướng phát triển

- Chạy full-pool (347 items) cho HY-MT — ước tính 4.8–5.3 giờ (CPU-only, bf16); hoặc fp32 + 8 threads (4 h).
- Hỗ trợ QNN/HTP on-device (cần Qualcomm hardware).
- Nếu CTranslate2 upstream hỗ trợ dynamic RoPE → HY-MT CT2 → latency giảm 50×.
- Error analysis có hệ thống (hiện là manual sampling, tùy chọn).

9. Phụ lục

9.1. Reproducibility

Lệnh chạy benchmark:

```
uv run python -m bench.run --manifest eval_data/mt_vi_en_eval_manifest.json --candidate hy-mt1.5-1.8b-hf-cpu --out bench-results/fleurs-mt/gold-set/hy-mt1.5-1.8b-hf-cpu
```

- Manifest:
 - eval_data/eval_manifest_v1.json (FLEURS)
 - eval_data/vivos_vi_eval_manifest.json (VIVOS)
 - eval_data/mt_vi_en_eval_manifest.json (MT).
- Model paths: models/ (CT2 weights, sherpa-onnx); HF cache (transformers).
- Beam config: xem bench/registry.py REGISTRY dict.
- Aggregation:
 - bench/scripts/aggregate_results.py → docs/benchmark/benchmark-results-fleurs-vivos.md
 - benchmark-results-raw.md (từ docs/benchmark/raw-results/*.csv).
- **Không tái lập được từ repo:** eval_data/ và bench-results/ bị .gitignore loại, và weight của các ứng viên mới không có trong assets.lock.toml. Các số trong báo cáo chỉ tái lập được trên máy đã tải model, không tái lập được từ kho một mình.

9.2. Limitations

- **CSV không giữ hypothesis:** raw-results/*.csv lưu input_text và đường dẫn reference nhưng không lưu câu dịch của mô hình, nên không tính lại được BLEU theo bất kỳ cách nào khác — mọi thay đổi trên đường chấm điểm đều đòi chạy lại model.
- **Script sinh CSV không có trong repo:** bước run_results.json → raw-results/*.csv là thủ công. Vì vậy bảng inventory không thể liệt kê beam width — CSV không có cột beam_size và không có script nào thêm được trong PR này.
- **Beam width không ghi theo dòng:** mỗi ứng viên chạy ở beam tối ưu riêng (Opus-MT 5, M2M-100 4), nên đây là so sánh theo best-config-per-model chứ không phải cùng một thiết lập. Thứ tự xếp hạng không đổi — M2M-100 dẫn dù beam hẹp hơn — nhưng mức BLEU tuyệt đối không so được với BLEU đã công bố. Beam width bản thân vẫn là open parameter 6 (ADR-020).
- **FLEURS references là informal spoken transcripts** → BLEU penalty cho output fluent/literary (ảnh hưởng HY-MT nhiều hơn m2m/opus).
- **VSS/Zipformer contamination:** Zipformer-vi train trên VSS; VIVOS cùng miền giọng đọc chuẩn → kết quả Zipformer-vi trên VIVOS có thể bị lạc quan. So sánh công bằng nhất nằm ở FLEURS.
- **Single test environment** — CPU-only Core i7-1165G7 (Tiger Lake, 4 cores / 8 threads), không GPU/NPU.
- **Chưa có on-device (QNN/HTP) numbers** — cần Qualcomm HTP hardware.
- **HY-MT chỉ gold-set** — full-pool chưa chạy; latency không comparable với CT2.
- **Text normalization hạn chế** — chỉ lowercase, không strip punctuation/số → WER/CER cao hơn các báo cáo dùng aggressive normalization.
- **RTF không so sánh chéo dataset** — Whisper có fixed overhead bất kể độ dài audio.

9.3. Chi tiết SNR grid (FLEURS ASR)

Model	Clean	15 dB	10 dB	5 dB	0 dB
Moonshine-en	0.2728	0.2648	0.2905	0.4123	0.6479
Moonshine-vi	0.2815	0.3058	0.3499	0.5013	0.7701
Whisper-en	0.1598	0.1877	0.214	0.2576	0.4039
Whisper-vi	0.3013	0.3134	0.4328	0.4445	0.6909
Zipformer-en	0.2857	0.2715	0.3144	0.4274	0.672
Zipformer-vi	0.0997	0.1146	0.1253	0.1477	0.2088

Bảng 15: FLEURS — WER theo SNR dưới steady noise.

Model	Clean	15 dB	10 dB	5 dB	0 dB
Moonshine-en	0.2728	0.2578	0.2608	0.2738	0.2768
Moonshine-vi	0.2815	0.3194	0.3398	0.3469	0.3835
Whisper-en	0.1598	0.1842	0.1819	0.1849	0.1957
Whisper-vi	0.3013	0.3042	0.3113	0.31	0.3429
Zipformer-en	0.2857	0.3004	0.3005	0.2973	0.3017
Zipformer-vi	0.0997	0.1069	0.1097	0.1184	0.1206

Bảng 16: FLEURS — WER theo SNR dưới impulsive noise.

9.4. Chi tiết SNR grid (VIVOS ASR)

Model	Clean	15 dB	10 dB	5 dB	0 dB
Moonshine-vi	0.2009	0.1731	0.1909	0.2547	0.4981
Whisper-vi	0.3463	0.3308	0.3364	0.3939	0.5214
Zipformer-vi	0.0513	0.0498	0.0491	0.0608	0.0924

Bảng 17: VIVOS — WER theo SNR dưới steady noise.

Model	Clean	15 dB	10 dB	5 dB	0 dB
Moonshine-vi	0.2009	0.2084	0.217	0.2598	0.3287
Whisper-vi	0.3463	0.3415	0.3409	0.336	0.3302
Zipformer-vi	0.0513	0.055	0.0482	0.0504	0.0503

Bảng 18: VIVOS — WER theo SNR dưới impulsive noise.